NeuroBeats

Promoter Seeker

Natan Jabłoński | Jan Malinowski | Michał Konon

Strategie szukanie obiecujących sekwencji



1. Informowana biologicznie

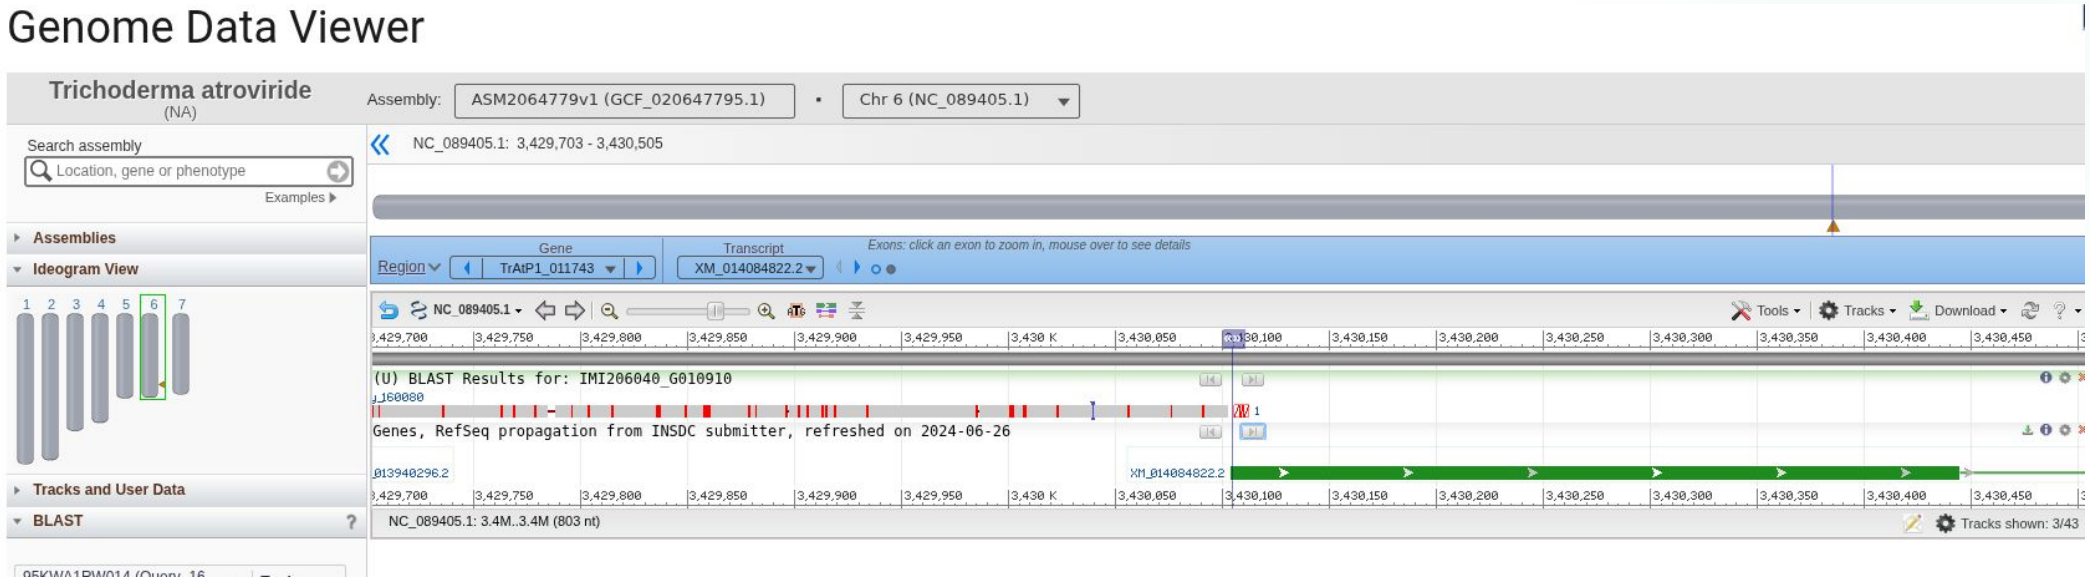
Szukaliśmy podstawowych szlaków metabolicznych o przewidywanej wysokiej aktywności. Szukamy homologów i ortologów genów w tych szlakach. Można ich użyć jako kandydatów na promotory albo

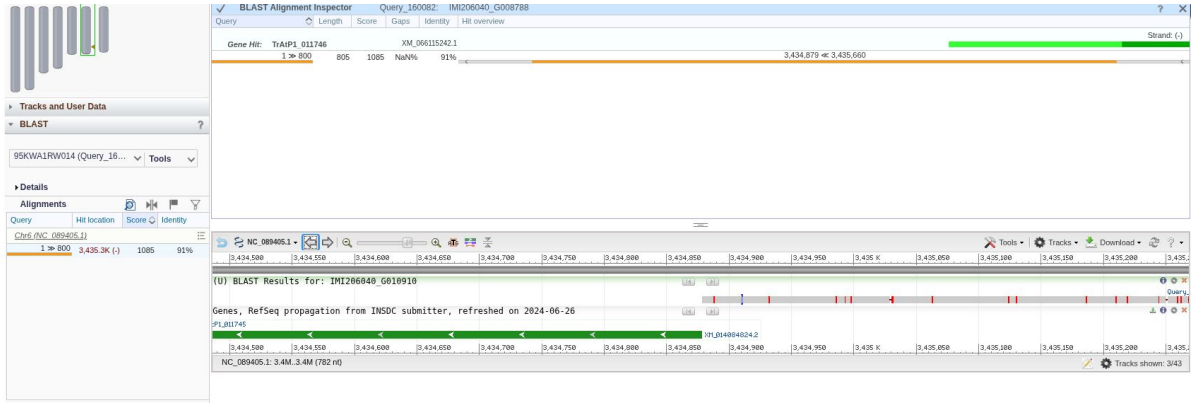


2.Strategia heurystyczna

Przeszliśmy przez wszystkie sekwencje adnotowane jako geny w genomie referencyjnym Trichoderma atroviride. Biorąc sekwencje 800 nukleotydów upstream od genu.

Szukanie obiecujących sekwencji na podstawie informacji genetycznej





Przyjęcie strategii heurystycznej

Biorąc pod uwagę że podane promotory mają długość równo 800. I zawsze kończą się przed sekwencją genu. Stwierdziliśmy że opłaca się pójść tą strategią dla wszystkich genów w genomie referencyjnym, żeby zyskać dużo rozsądnych kandydatów na promotory.

Strategia



1. Poszukiwanie motywu

Promotor nie jest jednorodną sekwencją. Na jego aktywność wpływają czynniki transkrypcyjne, które można określić jako motywy. Testując różne kombinacje czynników transkrypcyjnych może udać nam się stworzyć promotor o wysokiej aktywności.



2. Dobór kandydatów

Konieczne było stworzenie strategii doboru najlepszych kandydatów sekwencji promotorowych

Poszukiwanie Motywu

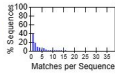
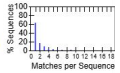
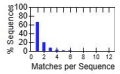
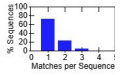
STREME
Sensitive, Thorough, Rapid, Enriched Motif Elicitation

For further information on how to interpret these results please access https://meme-suite.org/meme/doc/streme.html.
To get a copy of the MEME software please access https://meme-suite.org.

If you use STREME in your research, please cite the following paper:
Timothy L. Bailey, "STREME: accurate and versatile sequence motif discovery", *Bioinformatics*, Mar. 24, 2021. [full text]

Discovered Motifs | Inputs & Settings | Program Information | Motifs in MEME Text Format | Matching Sequences | Matching Sites | Results in XML Format

Discovered Motifs Next Top

Motif	Logo	RC Logo	P-value	E-value	Sites	More	Submit/Download	Positional Distribution	Matches per Sequence
1-AAAGAARAARAAAAAARA			5.6e-012	1.2e-010	523 (39.0%)	I	→		
2-AGYAGYAGYAGYAGYAGNHR			1.3e-006	2.7e-005	565 (42.1%)	I	→		
3-GRDGAKGRRGRDGRRGRBGRNGDDRWNRN			3.7e-005	7.9e-004	507 (37.8%)	I	→		
4-CTTCTTCTC			1.6e-003	3.3e-002	563 (42.0%)	I	→		

XSTREME
Motif Discovery and Enrichment Analysis

For further information on how to interpret these results please access https://meme-suite.org/meme/doc/xstreme-output-format.html.
To get a copy of the MEME software please access https://meme-suite.org.

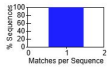
If you use XSTREME in your research, please cite the following paper:
Charles E. Grant and Timothy L. Bailey, "XSTREME: comprehensive motif analysis of biological sequence datasets", *BioRxiv*, September 3, 2021. [full text]

Motifs | Programs | Input Files | Program Information | Summary in TSV Format | Non-redundant Motifs in MEME Text Format

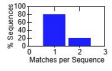
Motifs

Enriched motifs (E-value ≤ 0.05 and 3 best STREME motifs).

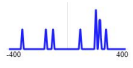
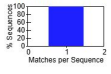
Expand All Clusters Collapse All Clusters

Motif Logo	Motif Source	Rank	E-value	Positional Distribution	Matches per Sequence	Similar Known Motifs	Sites
	1-AGCCAAGDBAYATMC (STREME)	1	5.41e-006			RIM101 (MA0368.1)	Motif Sites in GFF3

Reverse Complement ⇆

Motif Logo	Motif Source	Rank	E-value	Positional Distribution	Matches per Sequence	Similar Known Motifs	Sites
	2-GACAACTTCA (STREME)	1	5.41e-006				Motif Sites in GFF3

Reverse Complement ⇆

Motif Logo	Motif Source	Rank	E-value	Positional Distribution	Matches per Sequence	Similar Known Motifs	Sites
	3-GCAGCAGCRAGCTTG (STREME)	2	5.95e-005				Motif Sites in GFF3

Reverse Complement ⇆

Tomtom
Motif Comparison Tool

For further information on how to interpret these results please access https://meme-suite.org/meme/doc/tomtom-output-format.html.
To get a copy of the MEME software please access https://meme-suite.org.

If you use Tomtom in your research, please cite the following paper:
Shobhit Gupta, JA Stamatoyannopolous, Timothy Bailey and William Stafford Noble, "Quantifying similarity between motifs", *Genome Biology*, 8(2):R24, 2007. [full text]

Query Motifs | Target Databases | Matches | Settings | Program Information | Results in TSV Format | Results in XML Format

Query Motifs Next Top

Database	ID	Alt. ID	Preview	Matches	List
meme.txt	1-AGCCAAGDBAYATMC	STREME-1		7	MA0368.1 (RIM101), MA0313.1 (HAP2), MA0288.1 (CUP9), MA0386.2 (SPT15), MA0285.2 (CRZ1), MA0379.1 (MOT2), MA0359.3 (RAP1)
meme.txt	2-GACAACTTCA	STREME-2		5	MA0286.2 (CST6), MA2700.1 (pcr1), MA0382.3 (SKO1), MA0365.2 (RFX1), MA2707.1 (ACA1)
meme.txt	3-GCAGCAGCRAGCTTG	STREME-3		6	MA0394.1 (STP1), MA2699.1 (loz1), MA0287.1 (CUP2), MA0323.1 (IXR1), MA0290.1 (DAL81), MA0402.2 (SWI5)
meme.txt	4-WTCAAKKCKCTGATG	STREME-4		2	MA2701.1 (FZF1), MA0371.1 (ROX1)
meme.txt	5-WWAAAAGVMAYRATA	STREME-5		15	MA0277.1 (AZF1), MA2695.1 (ste11), MA0377.2 (SFL1), MA0343.2 (NDT80), MA2706.1 (SMP1), MA0327.1 (HMRA1), MA0296.2 (FKH1), MA2704.1 (RTG1), MA0356.1 (PHO2), MA0382.3 (SKO1), MA0288.1 (CUP9), MA0284.3 (CIN5), MA0390.2 (STB3), MA0370.1 (RME1), MA0388.1 (SPT23)

Target Databases Previous Next Top

Database	Used	Matched
JASPAR2026_CORE_fungi_non-redundant	193	33

Matches to 1-AGCCAAGDBAYATMC (STREME-1) Previous Next Top

Summary | Optimal Alignment

Warstwa Biologiczna Motywów

Katalog IUPAC

Konsensusy w kodzie IUPAC (np. SYGGRG, CCAAT, rejony A/T i G/C) reprezentujące całe rodziny elementów regulatorowych.

Stochastyczne Rozwijanie

Moduł wildcard_filling.py stochastycznie rozwija symbole IUPAC z uwzględnieniem obu nici DNA, budując bogatą różnorodność.

Kontrola Jakości

Funkcja limit_ns po każdej edycji wymusza udział N ≤ 10%, utrzymując długość 800 pz i pełną zgodność z API.

Dwie strategie doboru kandydatów (dwa filary)



1. Przeszukiwanie turniejowe/sortowanie

Promotor nie jest jednorodną sekwencją. Na jego aktywność wpływają czynniki transkrypcyjne, które można określić jako motywy.



2. Konstrukcja promotora przez model RL

Uczenie ze wzmocnieniem (PPO), w którym agent operuje na koktajlach motywów regulatorowych IUPAC, wspinając się od naturalnych promotorów do jeszcze silniejszych wariantów.

Filar I: Drabinka Genomowa / sortowanie

- **Ekstrakcja z genomu:** Skanujemy genom grzyba i wycinamy naturalne sekwencje promotorowe (800 pz przed każdym znanym genem).
- **Turniej Binarny (System Pucharowy):** Parujemy promotory w pojedynki 1-na-1. Sędzia API wyłania wygranego, który awansuje do kolejnej rundy.
- **Drastyczna oszczędność API:** Zamiast złożoności $O(N^2)$ (porównywania każdego z każdym), znajdujemy absolutnie najlepszy naturalny promotor w $O(N)$ zapytań.



Filar II: Wspinaczka RL

Start z Naturalnej Bazy

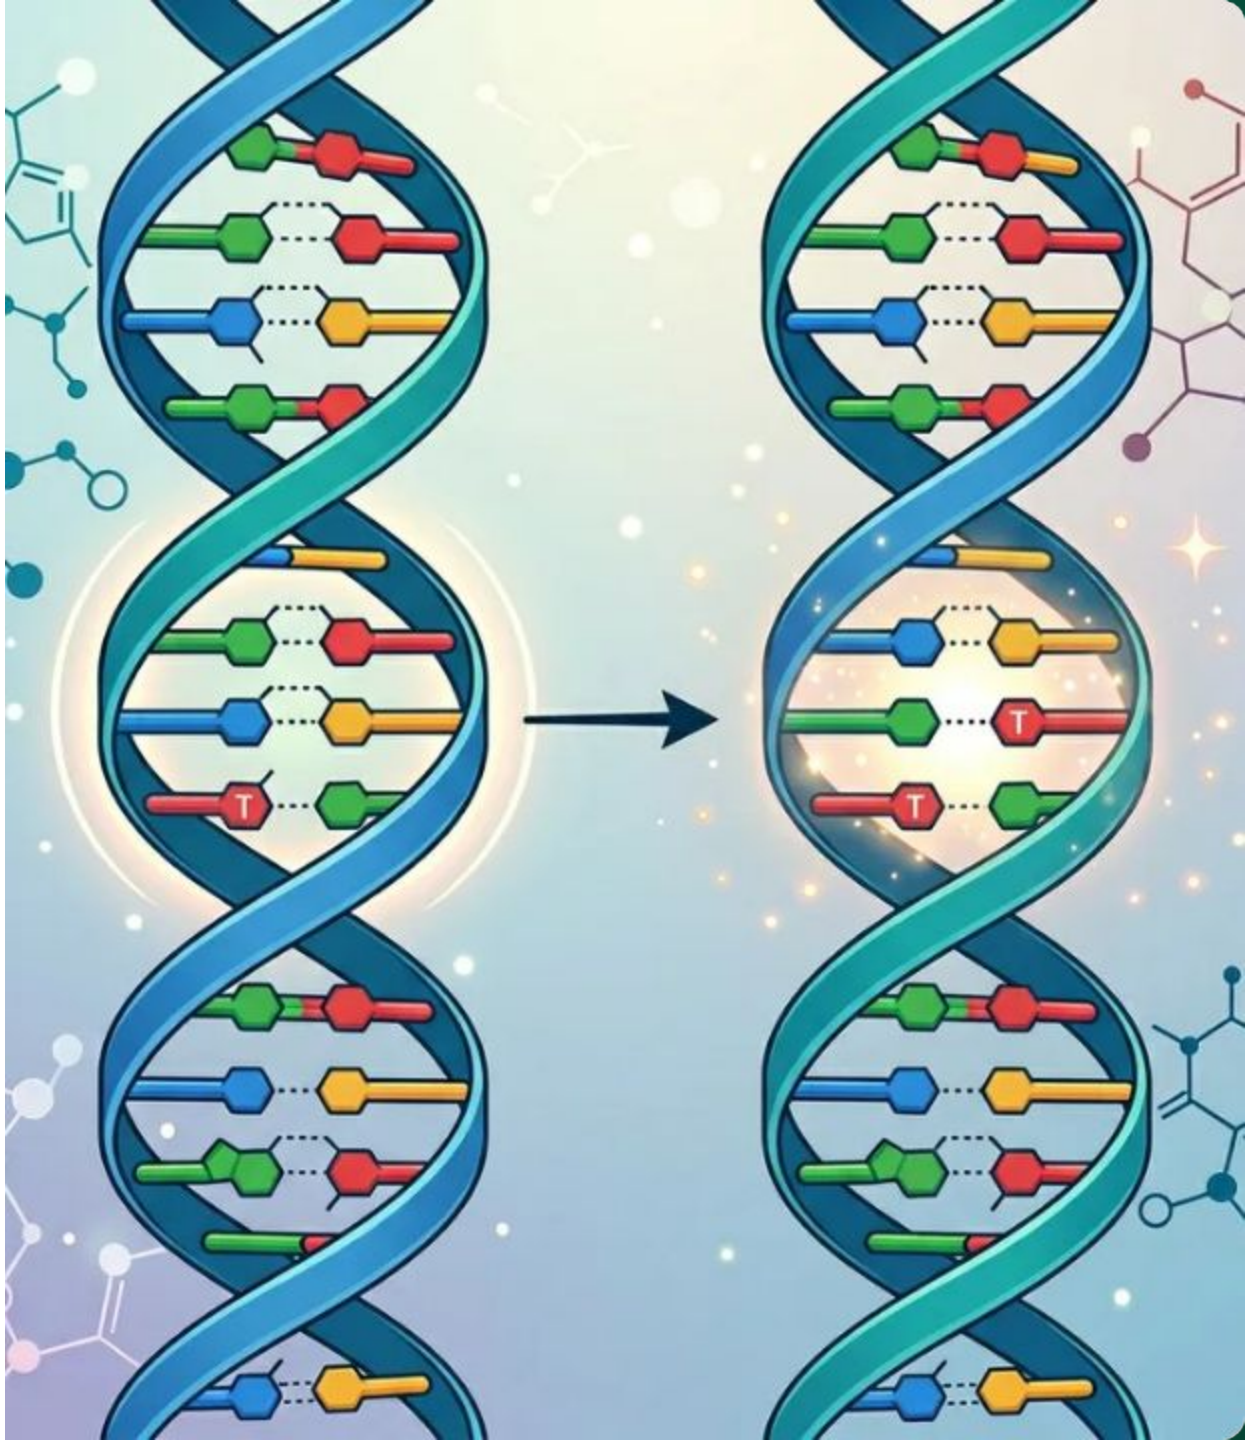
Agent (PPO) rozpoczyna epizod od wyłonionego naturalnego czempiona lub zbioru promotorów, traktując go jako stabilny szkielet.

Akcja: Koktajl Motywów IUPAC

Agent nie mutuje pojedynczych nukleotydów. Generuje ciągłe wagi i temperaturę doboru dla katalogu motywów (TATA, CCAAT, GC-rich), wklejając spójne klocki biologiczne.

Przełamanie Progu Gradientu

Zmiana grupy motywów modyfikuje ~200 pz naraz, dzięki czemu Sędzia API przyznaje wyraźne nagrody za wygraną.



Pytania?

Dziękujemy za uwagę!